

# 07 Régression Linéaire

mardi 18 octobre 2022

## 1. Modèle de régression linéaire Gaussien

-1-  $Y_i = a + bx_i + \varepsilon_i$ , où  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

-2-  $Y_i$  sont indépendantes

-3-  $Y_i$  ne sont pas identiquement distribuées

-4- Hypothèse/Conditions

1- Linéarité

2- Normalité (erreurs  $\sim N$ )

3- Homoscédasticité (variance des erreurs sont même)

4- Indépendance

## 2. Estimation de modèle de régression linéaire

-1- Log-vraisemblance

1-  $l(a, b, \sigma^2; y_1, \dots, y_n) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum (y_i - a - bx_i)^2$

2- 
$$\begin{cases} \hat{a} = \bar{Y} - \hat{b}\bar{x} \\ \hat{b} = \frac{S_{xy}}{S_x^2} \\ S_{\text{res}} = \hat{\sigma}_{MV}^2 = \frac{1}{n} \sum (y_i - \hat{a} - \hat{b}x_i)^2 \end{cases}$$

-2- Variables sans biais

1-  $\hat{\sigma}^2$  estimateur sans biais de  $\sigma^2$

1>  $\hat{\sigma}^2 = \frac{n}{n-2} \hat{\sigma}_{MV}^2$

2-  $\text{cov}(\hat{a}, \hat{b}) = -\frac{\hat{x}\sigma^2}{nS_x^2}$

-3- Lois des estimateur et indépendance

1-  $\hat{a} \sim \mathcal{N}\left(a, \frac{\sigma^2}{n} \left(1 + \frac{\hat{x}^2}{S_x^2}\right)\right)$

2-  $\hat{b} \sim \mathcal{N}\left(b, \frac{\sigma^2}{nS_x^2}\right)$

3-  $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-2}^2$

-4- Intervalles de confiance

1- Fonctions pivotales

$$\begin{aligned}
1 &> \frac{(\hat{a} - a)}{\sqrt{\frac{\sigma^2}{ns_x^2}}} \sim \mathcal{T}_{n-2} \\
2 &> \frac{(\hat{b} - b)}{\sqrt{\frac{\hat{\sigma}^2}{n} \left(1 + \frac{\bar{x}^2}{s_x^2}\right)}} \sim \mathcal{T}_{n-2} \\
3 &> \frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-2}^2
\end{aligned}$$

## -5- Qualité de l'ajustement et validation des hypothèses

### 1- Analyse de variance

$$1 > \frac{1}{n} \sum (Y_i - \bar{Y})^2 = \frac{1}{n} \sum (\bar{Y} - \hat{Y}_i)^2 + \frac{1}{n} \sum (Y_i - \hat{Y})^2 = \frac{1}{n} \sum (\bar{Y} - \hat{Y}_i)^2 + \hat{\sigma}_{MV}^2$$

$$a) S_Y^2 = S_{reg} + S_{res}$$

$$b) Si \forall i, Y_i = \hat{Y}_i \Rightarrow S_Y^2 = S_{reg}$$

$$c) Si \hat{b} = 0, \hat{Y}_i = \bar{Y} \Rightarrow S_Y^2 = S_{res}$$

### 2- Coefficient de détermination

$$1 > R^2 = \frac{S_{reg}}{S_Y^2} = \frac{S_{xY}^2}{S_x^2 S_Y^2} \in [0,1]$$

### 3- Analyse des résidus $\hat{\epsilon}_i$

1 > Homoscédasticité 同方差性

$$a) Var(\hat{\epsilon}_i) = (1 - h_{ii})\sigma^2, h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{ns_x^2}$$

## 3. Prédiction

### -1- Fonction pivotale pour $E(Y_0)$

$$-1- \begin{cases} E(Y_0) = E(\hat{Y}_0) \\ Var(\hat{Y}_0) = \sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right) \end{cases}$$

### -2- $\sigma^2$ connue

$$1 > \frac{\hat{Y}_0 - E(Y_0)}{\sqrt{\sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right)}} \sim \mathcal{N}(0,1)$$

$$2 > IC = \hat{Y}_0 \pm u_{1-\frac{\alpha}{2}} \sqrt{\sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right)}$$

### -3- $\sigma^2$ inconnue

$$1> \frac{\hat{Y}_0 - E(Y_0)}{\sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right)}} \sim \mathcal{T}_{n-2}$$

$$2> IC = \hat{Y}_0 \pm t_{n-2, 1-\frac{\alpha}{2}} \sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right)}$$

-2- Fonction pivotale pour  $Y_0$  au niveau  $1 - \alpha$

$$-1- \begin{cases} E(Y_0 - \hat{Y}_0) = 0 \\ Var(\hat{Y}_0 - Y_0) = \sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} \right) + \sigma^2 \end{cases}$$

-2-  $\sigma^2$  connue

$$1> \frac{\hat{Y}_0 - Y_0}{\sqrt{\sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} + 1 \right)}} \sim \mathcal{N}(0,1)$$

$$2> IC = \hat{Y}_0 \pm u_{1-\frac{\alpha}{2}} \sqrt{\sigma^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} + 1 \right)}$$

-3-  $\sigma^2$  inconnue

$$1> \frac{\hat{Y}_0 - Y_0}{\sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} + 1 \right)}} \sim \mathcal{T}_{n-2}$$

$$2> IC = \hat{Y}_0 \pm t_{n-2, 1-\frac{\alpha}{2}} \sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{(\bar{x} - x_0)^2}{ns_x^2} + 1 \right)}$$