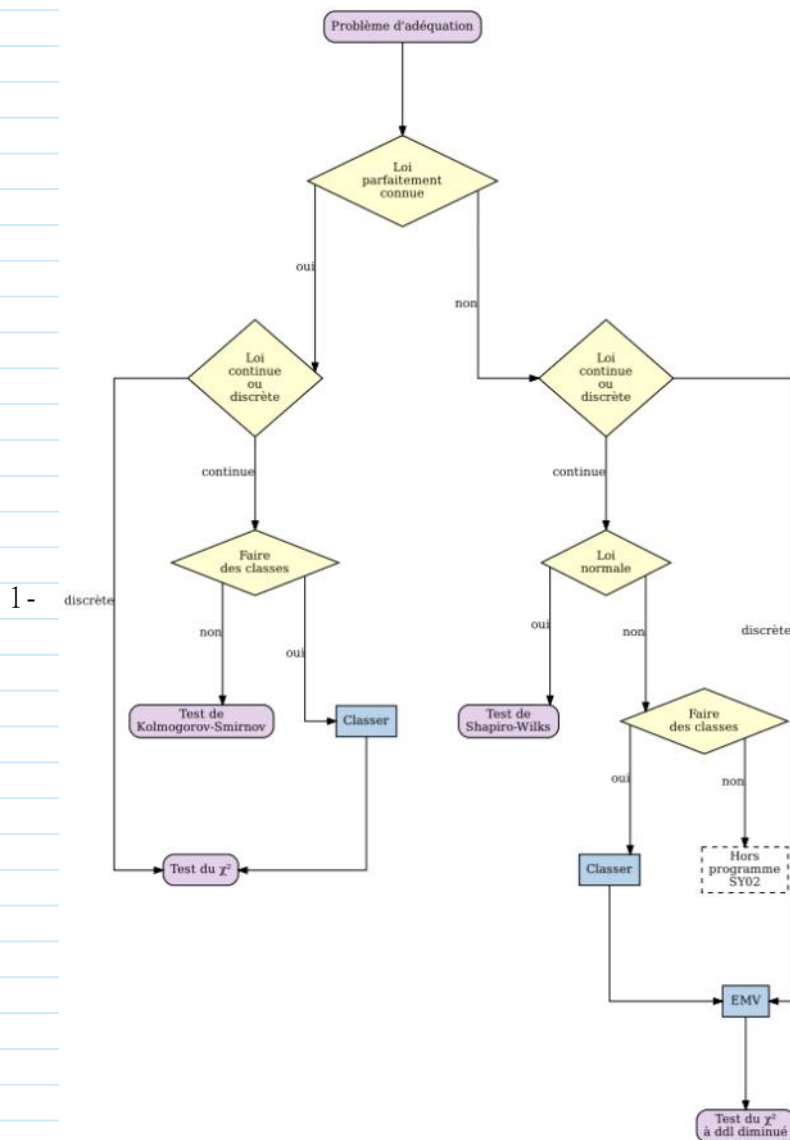


12&13 Tests d'adéquation et Tests d'Indépendance

mercredi 28 décembre 2022

1. Test d'adéquation 一致性 (entre 1 modèle)

-1- Introduction



-2- Test du χ^2 d'adéquation

1- vector aléatoire de nombre : $N = (N_1, \dots, N_K)$

2- $H_0: p_k = p_{k_0} \forall k$

3- Écart entre l'échantillon et l'hypothèse H_0

$$1> D^2 = (\chi^2) = \sum_{i=1}^K \frac{(N_i - np_{i_0})^2}{np_{i_0}} \sim \chi_{K-1}^2, -n \text{ est nombre total}$$
$$a) \Rightarrow D^2 = \sum \frac{N_i^2}{np_{i_0}} - n$$

2> Remplacer θ par son EMV $\hat{\theta}$, si $H_0 = (F_\theta)_{\theta \in \theta \subset \mathbb{R}^p}$

$$a) D^2 = \sum_{i=1}^K \frac{(N_i - n\hat{p}_{i_0})^2}{n\hat{p}_{i_0}} \sim \chi_{K-p-1}^2$$

4- Région critique

$$1> W = \{D^2 > \chi_{K-1; 1-\alpha}^2\}$$

-3- Test de Kolmogorov-Smirnov (K-S) (loi continue)


1- $H_0: F_x = F_0$

2- Fonction de répartition empirique correspondante

$$1> F_X(x) \approx^{n \rightarrow +\infty} \hat{F}(x) = \frac{1}{n} \text{card}\{i \in (1, \dots, n) | x_i \leq x\}$$

3- Écart entre l'échantillon et l'hypothèse H_0

$$1> D_n = \sup_x |\hat{F}(x) - F_0(x)|$$



2> Car il est discontinue


$$a) \Rightarrow D_n = \max_{1 \leq i \leq n} \max(|\hat{F}(x_i) - F_0(x_i)|, |\hat{F}(x_i^-) - F_0(x_i)|), -\hat{F}(x_i^-) = \lim_{x \rightarrow x_i^-} \hat{F}(x)$$

4- Région critique

$$1> W = \{D_n > d_{n; 1-\alpha}\} \text{ -- distribution de } K-S$$

-4- Test de Shapiro-Wilk/normalité (loi inconnue)

1- Diagramme quantile-quantile



2- Statistique de test de Shapiro-Wilk

$$1> w(X_1, \dots, X_n) = \frac{(\sum a_i X_{(i)})^2}{\sum (X_i - \bar{X})^2}$$

a) a_i sont des valeurs obtenues à partir des moments théorique des statistiques d'ordre d'une loi $\mathcal{N}(0, 1)$, ils sont antisymétrique 反对称关系 ($\forall k, a_{1+k} = -a_{n-k}$)

b) $W(X_1, \dots, X_n) = W(aX_1 + b, \dots, aX_n + b)$

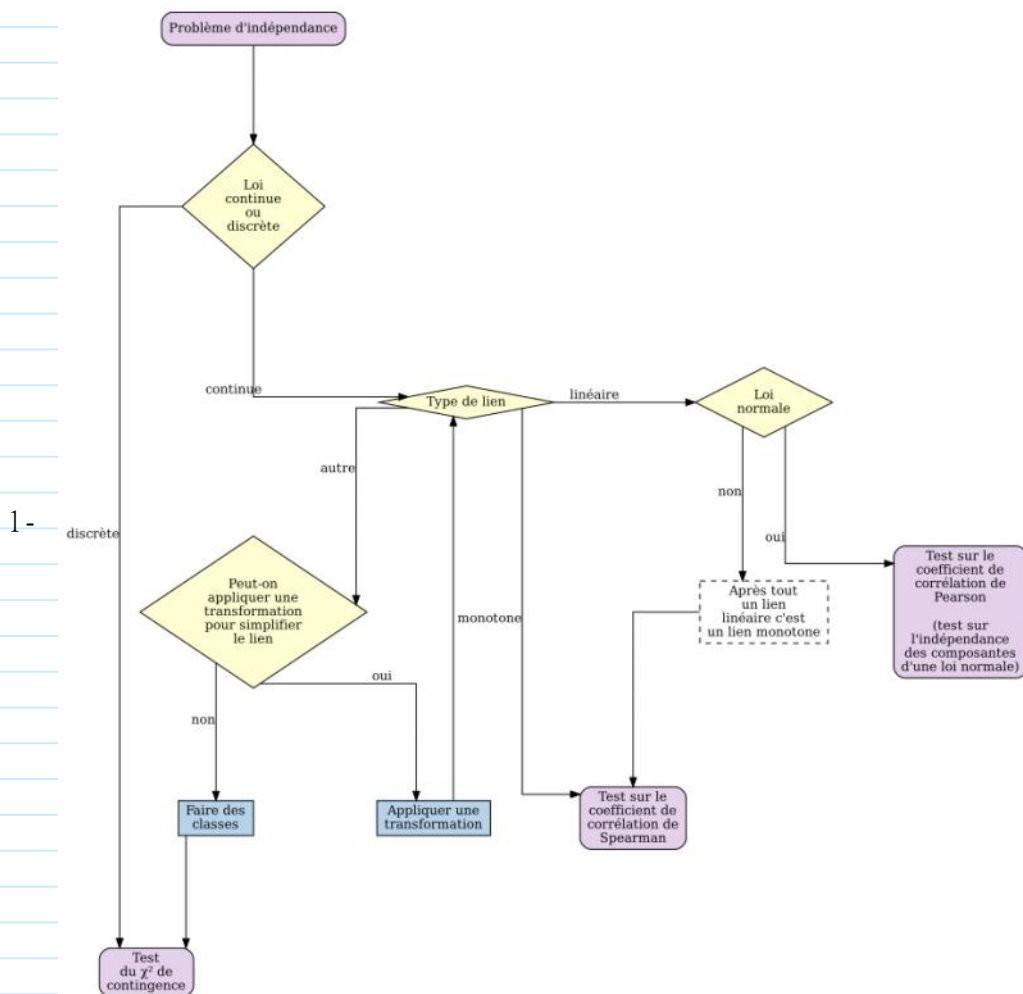
a) Ce test étant invariante aux changements de paramètres μ et σ^2 .

c) Région critique

a) $\{W(X_1, \dots, X_n) < w_{n, \alpha^*}\}$

2. Test d'indépendance (entre 2 échantillon)

-1- Introduction



-2- Test du χ^2 d'indépendance

1- χ^2 de contingences

X \ Y	1	...	j	...	J	
1			⋮			
⋮			⋮			
i	N_{ij}			$N_{i.}$
⋮						
I						
			$N_{.j}$			

$$2- D^2 = \sum \sum \frac{(N_{ij} - np_i p_j)^2}{np_i p_j}$$

$$3- H_0: D^2 \sum \sum \frac{\left(N_{ij} - \frac{N_i N_j}{n}\right)^2}{\frac{N_i N_j}{n}} = \sum \sum \frac{N_{ij}^2}{\left(\frac{N_i N_j}{n}\right)} - n \sim \chi_{(I-1)(J-1)}^2$$

4- RC

$$1> W = \{D^2 > \chi_{(I-1)(J-1); 1-\alpha^*}^2\}$$

-3- Coefficient de corrélation de Pearson (**Gaussien**)

$$1- R = \frac{S_{XY}}{\sqrt{S_X^2 S_Y^2}}$$

$$2- H_0: R \sqrt{\frac{n-2}{1-R^2}} \sim T_{n-2}$$

3- RC

$$1> W = \left\{ \left| R \sqrt{\frac{n-2}{1-R^2}} \right| > t_{n-2, 1-\frac{\alpha^*}{2}} \right\}$$

4- Remarque

1> Le coefficient de corrélation de Pearson ne doit être utilisé que quand le vecteur aléatoire (X, Y) suit au moins approximativement **une loi normale bidimensionnelle**.

2> Le coefficient de corrélation de Pearson n'indique qu'une dépendance linéaire entre deux variables.

-4- Coefficient de corrélation de Spearman : X_i et Y_j suivent des lois continues quelconques (**non Gaussien et continu**)

1- Notion

1> Noter (R_1, \dots, R_n) les rangs de (X_1, \dots, X_n) et (S_1, \dots, S_n) les rangs de (Y_1, \dots, Y_n)

a) Ex : si $(X_i) = (11.1, 13.2, 7.8)$ alors $(R_i) = (2, 3, 1)$

2- Coefficient de corrélation de Spearman

$$1> R_s = 1 - \frac{6 \sum D_i^2}{n(n^2 - 1)} \quad -D_i = R_i - S_i$$

2> Coefficient de Spearman mesure le **degré de dépendance monotone** entre X et Y.

3> Fonction pivotale (c'est mieux)

$$a) \quad H_0: \left(\sqrt{\frac{n-3}{1.06}} \right) \frac{1}{2} \ln \left(\frac{(1+R_s)}{1-R_s} \right) \sim^{app} N(0,1)$$

b) RC

$$a) \quad W = \left\{ \left| \left(\sqrt{\frac{n-3}{1.06}} \right) \frac{1}{2} \ln \left(\frac{(1+R_s)}{1-R_s} \right) \right| > u_{1-\frac{\alpha^*}{2}} \right\}$$